

Tarea 2: Cloud Strategy & Semantic Lab

Bases de Datos a gran escala

mail: claudio.torresf@usm.cl

Semestre 1 - 2026

Contexto

LogiTrans ha aprobado su Blueprint conceptual. Ahora, el desafío es aterrizar esa arquitectura a servicios reales en la nube y construir un prototipo funcional de búsqueda semántica para los manuales técnicos de la flota.

Parte A. Investigación de Ecosistemas Cloud (60 puntos)

Deben investigar y comparar dos proveedores de nube (ej. AWS vs Google Cloud, o Azure vs AWS) para implementar la solución diseñada en la Tarea 1.

1. Tabla de Mapeo de Componentes (20 pts)

Deben presentar una tabla comparativa detallando qué producto específico de cada nube utilizarían para cumplir con los siguientes requisitos:

Requisito de LogiTrans	Atributo a comparar	Nube A (ej. AWS)	Nube B (ej. GCP)
Data Lake (Bronze/Silver)	Almacenamiento de objetos (costo por GB)		
Data Warehouse (Gold)	Motor analítico (escalabilidad)		
Ingesta de Streaming	Procesamiento de eventos en tiempo real		
Alertas GPS (<5 seg)	Base de Datos de baja latencia (NoSQL)		
Orquestación	Manejo de flujos de trabajo (Pipelines)		

2. Análisis del Teorema CAP (20 pts)

Para el sistema de Alertas GPS y Desvíos, deben seleccionar una de las bases de datos NoSQL propuestas en su tabla anterior y detallar:

- **Clasificación:** ¿Es un sistema CP (Consistencia y Partición) o AP (Disponibilidad y Partición)?

- **Escenario de Falla:** ¿Qué sucede con los datos del camión si existe una partición de red entre los centros de datos de la nube elegida? Justifique. (Una partición de red ocurre cuando esos dos centros de datos dejan de poder comunicarse entre sí, pero ambos siguen encendidos y recibiendo datos de los camiones.)

3. Justificación de Elección (20 pts)

Eliján uno de los dos proveedores y justifiquen su decisión final considerando:

- Facilidad de integración entre los servicios elegidos.
- Modelo de costos (ej. ¿cuál ofrece mejor capa gratuita o cobro por uso para una startup como LogiTrans?).

Parte B. Laboratorio Práctico - Semantic Search con ChromaDB (40 puntos)

Implementarán un motor de búsqueda semántica que procese archivos de texto locales.

1. Especificaciones del Script (25 pts)

El script debe desarrollarse en Python utilizando la librería chromadb. La ejecución debe ser estrictamente a través de la terminal:

```
python main.py --input-folder data/
```

Requerimientos del Script:

- **Procesamiento de Archivos:** Debe iterar por todos los archivos .txt dentro de la carpeta indicada.
- **Lectura por Línea:** Cada línea dentro de un archivo .txt debe ser tratada como un documento individual en la colección.
- **Parsing de Metadatos:** El nombre del archivo tendrá el formato <source>—<id_doc>—<doc_number>.txt. El script debe extraer estos valores.
 - Ejemplo: Si el archivo es motor—01_manual—22.txt, la metadata en ChromaDB debe ser {'source': 'motor', 'id_doc': '01_manual', 'doc_number': '22'}.
- **Persistencia:** La base de datos debe guardarse en disco (no solo en memoria).

2. Validación y Búsqueda (15 pts)

El script debe incluir una sección de consulta donde el usuario pueda ingresar una frase.

- **Prueba:** Realizar una búsqueda con una frase que no use palabras exactas (ej: '¿Cómo actuar ante un incendio?' cuando el manual dice 'Protocolo de uso de extintores').
- **Output esperado:** El script debe imprimir el texto encontrado, la fuente (source), el id y el número de manual (doc_number). **Se deben imprimir los 3 resultados mas cercanos.**
- Ejemplo: Se entregan 3 archivos: engine-v8_manual-01.txt, cooling-system_manual-05.txt y safety-protocol_emergency-01.txt. Para la consulta: '¿Cómo actuar ante un incendio?', debería devolver la línea del Archivo 3 sobre el extintor, porque entiende que 'fuego' e 'incendio' son semánticamente lo mismo, junto a la metadata {'source': 'safety', 'id_doc': 'protocol_emergency', 'doc_number': '01'}.

Rúbrica de Evaluación

Criterio	Excelente (100 %)	Bueno (70 %)	Insuficiente (30 %)
Mapeo Cloud (20 pts)	Identifica productos correctos para todos los requisitos en ambas nubes.	Mapea la mayoría de los componentes pero omite alguno crítico.	Los productos no corresponden a la función solicitada.
Análisis CAP (20 pts)	Explica con precisión el compromiso CAP del servicio NoSQL elegido.	Identifica el tipo (AP/CP) pero la explicación del fallo es vaga.	No aplica conceptos del Teorema CAP.
Justificación (20 pts)	Argumentación sólida basada en costos, latencia y arquitectura Cloud.	Justificación genérica sin peso técnico.	No presenta una elección clara.
Ejecución y CLI (10 pts)	El script funciona correctamente usando el argumento -input-folder.	El script funciona pero la ruta está "hardcodeada" o tiene errores.	El script no se ejecuta.
Metadata Parsing (15 pts)	Extrae correctamente source y doc_number desde el nombre del archivo.	Extrae los datos de forma parcial o con errores de formato.	No implementa la lógica de metadatos.
Búsqueda Semántica (15 pts)	Demuestra resultados por contexto (sin coincidencia exacta de palabras).	La búsqueda funciona pero solo encuentra palabras exactas.	No implementa la consulta en ChromaDB.

Consideraciones

- La tarea puede ser desarrollada en grupo de máximo 3 estudiantes.
- Debe entregar un informe en formato PDF que incluya el nombre de los integrantes del equipo y los entregables. Además, se debe incluir un archivo .py con el script python. El nombre de los estudiantes debe estar en los comentarios del script python.
- Está permitido utilizar Inteligencias Artificiales para el desarrollo de la tarea, pero debe agregar el prompt utilizado como Anexo.

Fecha entrega: 10 Mayo 2026